

基于股票快照的价格移动方向预测：EDA 分析报告

Jingshu Liu

2026.5.17

1 EDA 目标

本次探索性数据分析（Explatory Data Analysis, EDA）的目标是在进入特征工程和建模之前，系统检查股票快照数据的完整性、字段结构、数据质量、订单簿合理性、标签分布以及潜在异常。该项目的核心任务是：基于股票订单簿快照数据，预测未来 5、10、20、40、60 个 tick 后的中间价移动方向。

EDA 阶段重点回答以下问题：

1. 数据文件是否完整，是否存在缺失交易日、缺失标的或缺失 session；
2. 原始 CSV 文件是否能够正常读取，是否存在空文件或读取失败文件；
3. 字段是否符合任务说明，是否存在缺失字段或字段命名差异；
4. 数据是否存在缺失值、重复行、无穷值等基础质量问题；
5. 订单簿价格与挂单量是否满足基本金融逻辑；
6. `n_midprice` 是否与买一价、卖一价规则基本一致；
7. 标签是否确实表示“未来 N 个 tick 的价格移动方向”；
8. 标签是否存在类别不均衡，后续建模是否需要加权或重采样；
9. 哪些变量需要在特征工程阶段进行变换或异常处理。

2 数据概览

表 1: 数据文件与样本概览

指标	结果
理论文件组合数	1580
实际读取文件数	1521
成功读取文件数	1521
读取失败文件数	0
空文件数	0
缺失文件组合数	59
异常额外文件组合数	0
总样本行数	3,040,479
总字段数	35

理论上，数据应包含 10 只股票、79 个交易日、上午与下午两个交易时段，因此理论文件组合数为：

$$10 \times 79 \times 2 = 1580.$$

实际读取到 1521 个文件，说明存在 59 个股票-日期-session 组合缺失。该问题不会阻止后续建模，但在时间序列划分和样本构造时需要注意，避免默认所有股票在所有日期都有完整数据。




图 1: 不同股票样本量分布

从图 1 可以看出，不同 sym_id 的样本量总体接近，说明 10 只股票的样本覆盖较均衡。不过，sym_id=5 的样本量相对较少，后续可以关注该标的是否存在更多缺失交易

session。




图 2: 不同日期样本量分布

图 2 显示，大多数日期的样本量接近 40,000，但部分日期样本量明显偏低。这与缺失 59 个文件组合的结论一致，说明部分交易日可能存在缺失股票或缺失 session。




图 3: 上午/下午 session 样本量分布

图 3 显示，上午和下午 session 的样本量总体接近，说明两个交易时段的数据覆盖较为平衡。

3 字段说明与字段检查

实际数据包含 35 个字段，核心字段包括表 2 所示内容。

表 2: 核心字段说明

字段类型	字段
标识字段	date, time, sym
最新价字段	n_close
成交字段	amount_delta
中间价字段	n_midprice
买盘价格字段	n_bid1 至 n_bid5
买盘挂单量字段	n_bsize1 至 n_bsize5
卖盘价格字段	n_ask1 至 n_ask5
卖盘挂单量字段	n_ysize1 至 n_ysize5
标签字段	label_5, label_10, label_20, label_40, label_60

需要注意的是, 实际数据中最新价字段为 `n_close`, 而不是部分说明中出现的 `close`; 标签字段使用下划线命名, 即 `label_5`、`label_10` 等。

4 数据质量检查

表 3: 基础数据质量检查

检查项	结果
缺失值	未发现明显缺失值
重复行数	0
Inf / -Inf	未发现
读取失败文件	0
空文件	0

基础数据质量较好, 未发现缺失值、重复行或无穷值。这说明后续可以直接进入异常检查、特征工程与建模准备, 而不需要大规模处理缺失值。

5 订单簿异常检查

订单簿数据需要满足基本的价格层级关系。正常情况下, 一般应有:

$$n_bid1 \leq n_ask1.$$

买盘内部应满足：

$$n_bid1 \geq n_bid2 \geq n_bid3 \geq n_bid4 \geq n_bid5.$$

卖盘内部应满足：

$$n_ask1 \leq n_ask2 \leq n_ask3 \leq n_ask4 \leq n_ask5.$$

表 4: 订单簿主要异常统计

异常类型	数量	比例
$n_bid1 > n_ask1$	30,853	1.01%
$n_bid2 > n_ask2$	32,468	1.07%
$n_bid3 > n_ask3$	33,806	1.11%
$n_bid4 > n_ask4$	34,696	1.14%
$n_bid5 > n_ask5$	35,674	1.17%
$n_bid2 > n_bid1$	308	0.01%
$n_bid3 > n_bid2$	170	0.01%
$n_bid4 > n_bid3$	88	约 0.00%
$n_bid5 > n_bid4$	54	约 0.00%
$n_ask2 < n_ask1$	1,307	0.04%
$n_ask3 < n_ask2$	1,168	0.04%
$n_ask4 < n_ask3$	802	0.03%
$n_ask5 < n_ask4$	924	0.03%
size 字段负数	0	0.00%

结果显示，买卖盘档位内部错序比例很低，挂单量字段也没有负值，说明订单簿结构总体合理。但约 1.01% 的样本出现 $n_bid1 > n_ask1$ ，即 crossed book 现象。该比例不算特别高，但后续特征工程时建议保留一个异常标记特征：

$$is_crossed_book = \mathbf{1}(n_bid1 > n_ask1),$$

并在建模阶段比较“保留异常样本”和“过滤异常样本”两种方案的表现。




图 4: 原始 bid-ask spread 分布

图 4 显示, 大部分样本集中在 0 附近, 但存在一部分负 spread, 说明确实存在 crossed book 或报价异常。




图 5: 截尾后的 bid-ask spread 分布

图 5 更清楚地显示了主体分布。多数样本的 spread 非常接近 0, 表明高频快照中买一卖一价格差通常较小。

6 Midprice 规则检查

数据说明中给出的中间价规则为：

1. 若 n_bid1 与 n_ask1 均不为 0，则：

$$n_midprice = \frac{n_bid1 + n_ask1}{2};$$

2. 若仅一方不为 0，则中间价取不为 0 的价格；

3. 若两方均为 0，则置为缺失。

对照该规则重新计算 $calc_midprice$ 后，与原始 $n_midprice$ 比较，得到表 5。

表 5: Midprice 规则检查结果

指标	结果
mismatch count	166,530
mismatch ratio	5.48%
mean absolute difference	7.28×10^{-5}
max absolute difference	0.00545

约 5.48% 的样本中，数据自带的 $n_midprice$ 与根据 n_bid1 、 n_ask1 重算结果存在差异。但平均绝对差异较小，说明大部分差异幅度有限。可能原因包括浮点数精度、原始数据源计算方式不同、bid/ask 为 0 时的特殊处理、crossed book 状态或快照对齐方式差异。

后续建模建议优先使用数据自带的 $n_midprice$ ，不要直接用重新计算的值覆盖它。可以额外构造 $midprice_diff$ 作为数据质量或异常状态特征。




图 6: n_midprice 分布

图 6 显示, `n_midprice` 分布以 0 为中心, 主体分布较集中, 符合涨跌幅标准化后的价格特征。在 -0.1 与 0.1 附近存在少量样本聚集, 可能与涨跌停限制或边界截断有关。

7 amount_delta 分布分析

`amount_delta` 表示从上一个 tick 到当前 tick 发生的成交金额变化。该字段分布极度右偏, 存在少数极端大值。




图 7: 原始 amount_delta 分布

图 7 几乎被极端值拉伸, 绝大多数样本挤在 0 附近, 说明直接使用原始 `amount_delta` 可能会影响模型稳定性。




图 8: $\log_{1p}(\text{amount_delta})$ 分布

经过 $\log_{1p}$ 变换后, 主体分布更加清晰。因此后续特征工程建议使用:

$$\log_amount_delta = \log(1 + \max(amount_delta, 0)),$$

以降低极端值影响。

8 标签方向检查

项目目标是根据当前及过去快照数据, 预测未来 N 个 tick 的中间价移动方向。为确认标签方向, 对每个文件内部分别检查两种定义:

未来方向:

$$x_t = n_midprice_{t+N} - n_midprice_t.$$

过去方向:

$$x_t = n_midprice_t - n_midprice_{t-N}.$$

标签规则为:

$$\phi(x) = \begin{cases} 0, & x < -\alpha, \\ 1, & -\alpha \leq x \leq \alpha, \\ 2, & x > \alpha. \end{cases}$$

其中, $N = 5, 10$ 时 $\alpha = 0.0005$, $N = 20, 40, 60$ 时 $\alpha = 0.001$ 。

检查结果显示，五个标签均与未来方向完全匹配。

表 6: 标签方向检查结果

标签	future match ratio	结论
label_5	1.0000	未来方向
label_10	1.0000	未来方向
label_20	1.0000	未来方向
label_40	1.0000	未来方向
label_60	1.0000	未来方向

因此，后续建模目标可以明确为：使用当前及过去 100 个 tick 的快照特征，预测未来 5、10、20、40、60 个 tick 的中间价移动方向。

9 标签分布分析


五个预测窗口的标签分布如表 7 所示。

表 7: 标签分布统计


标签	下跌 0	不变 1	上涨 2
label_5	460,804 / 15.16%	2,122,348 / 69.80%	457,327 / 15.04%
label_10	647,453 / 21.29%	1,762,358 / 57.96%	630,668 / 20.74%
label_20	520,965 / 17.13%	2,006,167 / 65.98%	513,347 / 16.88%
label_40	741,438 / 24.39%	1,586,710 / 52.19%	712,331 / 23.43%
label_60	857,580 / 28.21%	1,361,229 / 44.77%	821,670 / 27.02%

可以看出，短窗口 label_5 中“不变”类占比最高，达到 69.80%。随着预测窗口变长，价格发生明显移动的比例整体上升，label_60 是五个任务中类别最均衡的标签。


需要注意的是，label_20 的“不变”类比例高于 label_10，这是因为 $N = 20, 40, 60$ 时阈值 $\alpha = 0.001$ ，比 $N = 5, 10$ 的阈值 0.0005 更大，因此更多小幅波动会被归入“不变”类。




(a) label_5




(b) label_10



(c) label_20



(d) label_40



(e) label_60

图 9: 五个预测窗口的标签分布

标签分布说明后续训练不能只看 accuracy。尤其在 label_5 和 label_20 中，如果模型倾向于预测类别 1，虽然准确率可能较高，但对上涨和下跌方向的预测价值有限。后续评估应重点关注类别 0 和类别 2 的 precision、recall 与 F0.5。

10 数值字段相关性分析




图 10: 主要数值字段相关性热力图

图 10 显示, 价格类字段之间高度相关, 包括 `n_close`、`n_midprice`、`n_bid*` 和 `n_ask*`。这说明直接使用所有价格字段可能存在较强冗余。后续可以构造更有意义的组合特征, 例如:

$$\begin{aligned}
 spread &= n_ask1 - n_bid1, \\
 bid_depth &= \sum_{i=1}^5 n_bsize_i, \\
 ask_depth &= \sum_{i=1}^5 n_asize_i, \\
 imbalance &= \frac{bid_depth - ask_depth}{bid_depth + ask_depth + \epsilon}.
 \end{aligned}$$

标签之间也存在明显正相关, 说明未来不同窗口的价格移动方向具有一定一致性。但标签与单个原始价格字段之间的线性相关性不强, 说明后续需要依赖时序特征、订单簿结构特征和非线性模型。

11 初步结论

1. 数据整体质量较好。所有 1521 个实际文件均成功读取，没有空文件、读取失败文件、重复行、缺失值或无穷值。
2. 文件完整性存在轻微缺失。理论应有 1580 个文件组合，实际存在 1521 个，缺失 59 个组合，无异常额外组合。
3. 股票和 session 样本量总体均衡，但部分日期样本量偏低，后续训练/验证划分应按 `date_id` 进行，避免随机划分导致时间泄漏。
4. 订单簿结构总体合理，`size` 字段无负数，`bid/ask` 档位内部错序比例很低。但约 1.01% 样本存在 `n_bid1 > n_ask1`，需要在特征工程或清洗阶段处理。
5. `n_midprice` 与根据 `bid1/ask1` 规则重算的中间价存在约 5.48% 不一致，但平均绝对误差较小。建议后续优先使用数据自带的 `n_midprice`。
6. `amount_delta` 分布极度右偏，存在少量极端大值，后续建议使用 `log1p` 变换。
7. 标签方向检查确认所有标签均表示未来方向，适合作为监督学习目标。
8. 标签存在明显类别不均衡，尤其是 `label_5` 和 `label_20`，后续建模应避免单纯追求 `accuracy`。

12 后续建议

12.1 数据清洗建议

1. 不建议直接删除所有 `crossed book` 样本，而是先构造 `is_crossed_book` 特征，并比较过滤前后的模型表现。
2. 保留数据自带的 `n_midprice`，不要使用重算值覆盖。
3. 对 `amount_delta` 构造 `log_amount_delta` 特征。
4. 可对 `spread`、`amount_delta` 等变量进行截尾或分位数裁剪，减少极端值影响。
5. 对缺失文件组合做好记录，但不需要人为补齐。

12.2 特征工程建议

建议构造以下特征：

表 8: 后续特征工程建议

特征类型	示例
价差特征	<code>spread = n_ask1 - n_bid1</code>
深度特征	<code>bid_depth, ask_depth</code>
不平衡特征	<code>imbalance</code>
成交变换特征	<code>log_amount_delta</code>
异常标记特征	<code>is_crossed_book</code>
时序统计特征	过去 5、10、20、50、100 tick 的均值、标准差、最大值、最小值
收益率特征	<code>midprice_return_1, midprice_return_5, midprice_return_10</code>
分组特征	<code>sym_id, date_id, session</code>

12.3 数据划分建议

不建议随机划分训练集和验证集。由于任务具有明显时间序列属性，应按 `date_id` 划分，例如：

- 较早日期作为训练集；
- 中间日期作为验证集；
- 较晚日期作为测试集或保留集。

这样可以更接近真实预测场景，避免未来信息泄漏。

12.4 建模与评估建议

1. 每个预测窗口可以分别训练一个三分类模型。
2. 由于类别不均衡，建议使用 `class_weight` 或样本权重。
3. 不应只看 `accuracy`，应重点评估上涨类和下跌类。
4. 推荐指标包括 `precision`、`recall`、`F0.5` 和混淆矩阵。
5. 可先使用 Logistic Regression 或 ExtraTrees 建立 baseline，再使用 LightGBM、Hist-GradientBoosting 或 1D-CNN 进行增强。

13 本阶段结论

EDA 结果表明，本项目数据整体质量较好，可以进入下一阶段。后续重点不在于大规模清洗缺失值，而在于处理类别不均衡、构造有效订单簿特征、控制极端值影响，并采用正确的时间序列训练/验证划分方式。