

基于股票快照的价格移动方向预测

Stock Movement Prediction

期末大作业最终答辩报告

课程：金融大数据与量化分析

组员：陶重光（模型架构设计和工程实现） 刘婧姝（EDA、数据清洗、特征工程和报告撰写）

报告主题：目标与数据、清洗与特征、模型与工程、结果对比与后续优化

日期：2026 年 6 月 18 日

目录

1 项目背景与任务定义	3
1.1 问题背景	3
1.2 输入与输出	3
1.3 标签定义	3
1.4 评价口径	4
2 数据理解与 EDA	4
2.1 数据规模与完整性	4
2.2 基础数据质量	5
2.3 K 线图绘制与价格路径理解	5
2.4 订单簿异常检查	5
2.5 Midprice 规则检查	6
2.6 成交金额与标签分布	6
3 数据清洗与防泄露设计	6
3.1 文件排序与样本构造	6
3.2 数值化清洗	6
3.3 异常盘口过滤与保留策略	6
3.4 历史窗口约束	7
3.5 训练/验证划分	7
4 特征工程	7
4.1 从 207 个表格特征到 922 维最终向量	7
4.2 原始盘口与价格特征	7
4.3 流动性与盘口压力特征	7
4.4 时序行为特征	8
4.5 成交与订单流特征	8
4.6 时间位置特征	8
4.7 防泄露特征管理	8
5 模型设计与工程实现	8
5.1 五个 horizon 分别建模	8
5.2 XGBoost 多分类模型	8
5.3 分标签推理阈值	9
5.4 工程实现与复现保障	9
6 实验迭代过程	10
6.1 迭代主线	10
6.2 结果展示口径	10

7 实验结果	11
7.1 三版结果对比	11
7.2 最终平台结果	11
8 结果解释与经验总结	13
8.1 分类概率不等于预期收益	13
8.2 阈值是核心超参数	13
8.3 日期切分更接近真实评估	13
8.4 长 horizon 更适合收益目标	13
8.5 工程一致性影响最终成绩	13
9 不足与后续优化方向	13
9.1 从方向概率转向交易期望值	13
9.2 概率校准与排序模型	14
9.3 分组阈值稳定性	14
9.4 短 horizon 强化收益过滤	14
9.5 长 horizon 强化趋势与成交流量	14
9.6 提交 QA 流程标准化	14
10 总结	14
A 附录：最终结果快速复盘	15
B 附录：报告中使用的关键数字	15

摘要

本项目研究基于股票限价订单簿快照的短期价格移动方向预测问题。任务要求使用当前及历史 tick 的快照信息，分别预测未来 5、10、20、40、60 个 tick 后中间价相对于当前中间价的移动方向，标签为下跌、不变、上涨三类。项目流程包括数据理解、探索性数据分析、数据清洗、标签验证、订单簿特征工程、XGBoost 多分类模型训练、阈值推理、平台提交与结果分析。

在数据层面，我们首先完成了 1521 个行情文件的读取与质量检查，确认实际读取文件均可用，同时发现 59 个理论股票-日期-session 组合缺失、约 1% 的 crossed book 样本、约 5.48% 的 midprice 小幅不一致，以及明显的标签类别不均衡。在特征层面，项目从原始订单簿快照出发，构造价格、价差、深度、不平衡、订单流、成交、波动、时间位置和多窗口历史摘要等特征，并在最终 XGBoost 管线中形成 922 维输入向量。在模型层面，项目为五个 horizon 分别训练 XGBoost 三分类模型，使用 `multi:softprob` 输出三类概率，并在推理阶段通过分标签置信阈值控制交易信号数量。

最终主线版本采用 Date63 out-of-time holdout 与 turbo 推理修复。平台结果显示，label_20、label_40、label_60 的 model score 为正，最终五个 horizon 的 total PnL 合计为 40.60。其中 label_40 的 model score 最高，label_60 的 single PnL 较高；短 horizon 的 precision 较高，但 single PnL 低于平台基准。实验说明，单纯提高方向分类 precision 并不等价于提高收益，后续优化应从方向概率进一步转向 positive expected value 信号筛选。

1 项目背景与任务定义

1.1 问题背景

限价订单簿 (limit order book) 记录市场中不同价格档位的买卖委托信息，是高频交易与短期价格预测中最重要的数据来源之一。相较于只使用日频或分钟级行情数据，tick 级订单簿快照能够更细致地反映买卖双方的即时供需状态、流动性变化、成交活跃度和短期价格压力。

本项目的核心问题是：给定股票在某一时刻及其历史一段时间内的订单簿快照，预测未来若干 tick 后中间价的移动方向。该任务具有典型的金融机器学习特点：

- 输入数据维度高，且包含价格、挂单量、成交额、时间位置等多类信息；
- 标签存在明显类别不均衡，尤其短 horizon 中“不变”类别占比较高；
- 数据具有时间序列属性，随机划分训练集和验证集容易造成时间泄露；
- 模型评价不能只看分类准确率，还需要结合 precision、recall、F0.5、覆盖率和 PnL。

1.2 输入与输出

项目输入为股票快照 CSV 文件。每个文件对应一只股票、一个交易日、一个上午或下午交易时段，命名格式为：

snapshot_sym<xx>_date<yy>_am/pm.csv

核心字段包括 date、time、sym、amount_delta、n_close、n_midprice、五档买卖价格、五档买卖挂单量以及五个标签列。项目输出为五个三分类预测结果：

表 1: 五个预测任务

标签	预测间隔	类别含义
label_5	5 ticks	0 跌 / 1 不变 / 2 涨
label_10	10 ticks	0 跌 / 1 不变 / 2 涨
label_20	20 ticks	0 跌 / 1 不变 / 2 涨
label_40	40 ticks	0 跌 / 1 不变 / 2 涨
label_60	60 ticks	0 跌 / 1 不变 / 2 涨

1.3 标签定义

设当前 tick 的中间价为 m_t ，未来 N 个 tick 后的中间价为 m_{t+N} ，定义

$$x_t^{(N)} = m_{t+N} - m_t.$$

标签函数为

$$\phi(x) = \begin{cases} 0, & x < -\alpha, \\ 1, & -\alpha \leq x \leq \alpha, \\ 2, & x > \alpha. \end{cases}$$

其中, $N = 5, 10$ 时使用较小阈值 $\alpha = 0.0005$, $N = 20, 40, 60$ 时使用较大阈值 $\alpha = 0.001$ 。因此, 短 horizon 更关注非常短期的微小方向变化, 长 horizon 则允许更大幅度的价格波动后再判定上涨或下跌。

1.4 评价口径

平台返回的主要指标包括 precision、recall、F0.5、total PnL、single PnL 和 model score。F0.5 的一般形式为

$$F_{0.5} = \frac{(1 + 0.5^2)PR}{0.5^2P + R},$$

其中 P 表示 precision, R 表示 recall。与 F1 相比, F0.5 更强调 precision, 但如果 recall 过低, 即使 precision 很高, F0.5 仍会很差。本项目结果也验证了这一点: 高阈值版本的 precision 很高, 但由于信号过于稀疏, recall、F0.5 和 PnL 均表现较差。

2 数据理解与 EDA

2.1 数据规模与完整性

EDA 阶段首先对文件完整性与可读性进行检查。理论上, 数据应包含 10 只股票、79 个交易日、上午与下午两个 session, 因此理论文件组合数为

$$10 \times 79 \times 2 = 1580.$$

实际读取到 1521 个文件, 读取失败文件数为 0, 空文件数为 0, 异常额外文件组合数为 0, 但存在 59 个理论文件组合缺失。原始总样本行数为 3,040,479, 总字段数为 35。

表 2: EDA 数据概览

指标	结果
理论文件组合数	1580
实际读取文件数	1521
成功读取文件数	1521
读取失败文件数	0
空文件数	0
缺失文件组合数	59
异常额外文件组合数	0
总样本行数	3,040,479
总字段数	35

这说明数据整体可用, 但不能默认所有股票在所有日期和 session 中均完整存在。因此, 在训练/验证划分和特征构造时, 应以真实存在的文件为单位处理, 避免人为补齐不存在的交易片段。

2.2 基础数据质量

基础数据质量检查结果显示：未发现明显缺失值，重复行数为 0，Inf / -Inf 未发现，读取失败文件和空文件均为 0。这意味着本项目不需要进行大规模缺失值填补，数据清洗的重点转向订单簿异常、midprice 一致性、成交额极端值和类别不均衡。

2.3 K 线图绘制与价格路径理解

在数据理解阶段，除表格统计外，我们还将单个股票、单个日期和单个 session 内的 tick 级快照还原为 K 线图，用于直观检查价格路径和时间顺序。具体做法是以文件为单位按 time 升序排列样本，再在固定 tick 窗口或固定时间窗口内聚合 $n_midprice$ / n_close ，得到每个窗口的 open、high、low、close；同时可用 $amount_delta$ 作为成交活跃度的辅助观察变量。

K 线图在本项目中的作用主要有三点。第一，它帮助确认同一文件内快照顺序是否连续，避免后续 rolling 和 lag 特征建立在错误时间顺序上。第二，它把 label 所描述的“未来若干 tick 后价格移动方向”放回实际价格路径中观察，使我们更容易理解短 horizon 中大量“不变”标签的来源。第三，在模型推理阶段，K 线图可以叠加上涨/下跌预测信号，用于检查模型是否只在局部噪声中交易，还是能够捕捉相对清晰的趋势或反转片段。




图 1: K 线图绘制示意：将 tick 级快照按窗口聚合为 open/high/low/close，用于检查价格路径、时间顺序和后续预测信号位置

2.4 订单簿异常检查

正常订单簿中，买一价一般不应高于卖一价，即 $n_bid1 \leq n_ask1$ ；买盘内部应满足买一到买五价格递减，卖盘内部应满足卖一到卖五价格递增。EDA 发现，买卖盘档位内部错序比例很低，size 字段没有负数，说明订单簿总体结构合理。但约 1.01% 的样本存在 $n_bid1 > n_ask1$ ，即 crossed book 现象。

对于 crossed book，项目没有简单地把所有样本删除。原因是此类样本可能来自市场微观结构、快照对齐误差或报价更新延迟，直接删除可能损失部分有信息量的样本。因此，在阶段性特征工程中采用了“保留样本 + 增加异常标记”的策略；在最终训练管线中，则进一步结合平台口径过滤涨停、买卖一缺失等异常样本，保证训练矩阵稳定。

2.5 Midprice 规则检查

课程任务中通常将中间价定义为

$$\text{midprice} = \frac{\text{ask1} + \text{bid1}}{2}.$$

当 bid1 或 ask1 为 0 时，数据说明中有特殊规则。EDA 中根据 bid1/ask1 重新计算 midprice，并与原始 n_midprice 比较，发现 mismatch count 为 166,530，mismatch ratio 为 5.48%，mean absolute difference 为 7.28×10^{-5} ，max absolute difference 为 0.00545。

这一结果说明，原始 n_midprice 与重算值存在少量不一致，但大多数差异幅度有限。由于标签本身基于原始数据构造，项目没有直接覆盖原始 n_midprice，而是倾向于保留原始字段，并构造 midprice 差异或异常标记作为辅助信息。

2.6 成交金额与标签分布

EDA 发现 amount_delta 分布极度右偏，存在少数极端大值。若直接使用原始 amount_delta，模型可能过度受极端样本影响。因此，特征工程中构造了 log1p 变换后的成交金额特征，以压缩极端值。

五个标签的分布存在明显类别不均衡。短 horizon 中“不变”类别占比较高，label_5 的不变类比例达到约 69.80%；随着 horizon 变长，明显上涨或下跌的比例整体上升。标签分布表明，模型评估不能只看 accuracy。如果模型倾向于预测“不变”，可能获得较高准确率，但对交易决策真正有意义的上涨和下跌信号并不强。因此，最终报告重点使用 precision、recall、F0.5、PnL 和 model score 解释结果。

3 数据清洗与防泄露设计

3.1 文件排序与样本构造

项目首先解析文件名中的 date、session 和 sym 信息，保持时间顺序处理样本。在最终训练管线中，数据以原始快照文件为基本单位构造特征，避免把不同股票、不同日期或不同交易时段的历史状态错误拼接在一起。

3.2 数值化清洗

在进入模型前，代码对数值字段进行统一清洗，处理 NaN、Inf 等问题，保证训练矩阵稳定。EDA 已经表明原始数据没有明显缺失和 Inf，因此此处更多是工程层面的稳健性保障。

3.3 异常盘口过滤与保留策略

项目在不同阶段采用了两类策略：

- 阶段性特征工程中，crossed book 样本不直接删除，而是保留并加入异常标记；
- 最终训练与提交版本中，为了提高平台输入稳定性，进一步过滤涨跌停、买卖一缺失等明显不可用样本。

这种处理方式的核心思想是：对于可能有信息量的市场异常，尽量转化为特征；对于明显破坏模型输入稳定性或平台推理口径的异常，则在样本构造阶段过滤。

3.4 历史窗口约束

课程任务强调使用过去 100 个 tick 快照信息。项目在特征构造时只使用当前 tick 和历史 tick，不使用未来 tick。最终模型使用最近 5 帧完整特征，并加入 5/10/20/40/80/100 tick 的历史摘要特征。每组前若干行由于历史窗口不足会被跳过，以保证输入特征口径一致。

3.5 训练/验证划分

项目避免随机划分训练集和验证集。原因是股票快照数据具有明显时间序列属性，随机划分会使训练集包含验证集之后的市场状态，从而造成未来信息泄露。最终主线版本采用 Date63 holdout，即使用 out-of-time 日期切分，更接近真实预测未来的评估场景。

4 特征工程

4.1 从 207 个表格特征到 922 维最终向量

阶段性特征工程报告中，项目曾将 1521 个原始 CSV 文件处理为建模可用的 parquet 文件，最终得到 2,889,900 个样本、218 个总列和 207 个模型输入特征。该版本主要用于建立稳定的数据清洗、rolling 构造、防泄露和统一特征列接口。

最终答辩版本在此基础上进一步扩展为 XGBoost 全量训练管线。特征体系从 182 个基础因子出发，通过最近 5 帧完整特征拼接和多个历史窗口摘要，形成 922 维最终输入向量。其设计目标是：在传统树模型中尽可能保留局部时序信息，同时避免直接使用未来 tick。

4.2 原始盘口与价格特征

基础特征保留了 n_close、n_midprice、五档买价、五档卖价、五档买盘挂单量、五档卖盘挂单量等字段。这些字段直接刻画当前订单簿截面，是所有后续组合特征的基础。

4.3 流动性与盘口压力特征

项目构造了 spread、depth、imbalance、micro price 等特征：

- spread 反映买卖价差和市场流动性；
- bid depth 与 ask depth 反映买卖盘挂单厚度；
- imbalance 衡量买卖盘相对力量；
- micro price / weighted midprice 将价格与挂单量结合，捕捉买卖压力对短期价格的影响。

这些特征比原始价格字段更接近市场微观结构含义，也是订单簿预测中较核心的特征类型。

4.4 时序行为特征

为了让 XGBoost 获得时间序列信息,项目构造了 lag、rolling mean、rolling standard deviation、ROC、volatility、price slope、price percentile 等特征。这些特征用于描述过去一段时间内价格和订单簿状态的趋势、波动和相对位置。

4.5 成交与订单流特征

成交金额和订单流对短期价格方向有重要影响。项目构造了 amount 相关特征、log 变换特征、VPIN 类成交波动特征、OFI (order flow imbalance)、orderbook pressure、weighted depth imbalance、book curvature 等扩展特征。这些特征试图从成交强度、买卖盘变化和订单簿形状中提取预测信号。

4.6 时间位置特征

项目加入 time_seconds、time_interval 等时间位置特征,用于刻画不同交易时段内可能存在的活跃度差异。例如上午、下午或 session 内不同阶段的波动性和成交强度可能不同,时间特征可以帮助模型识别此类规律。

4.7 防泄露特征管理

项目特别注意不把标签列、未来价格信息或不应作为特征的追踪字段输入模型。阶段性特征工程中,feature_columns.json 不包含 label_5、label_10、label_20、label_40、label_60,也不包含 date、time、source_file 等追踪字段。最终训练管线同样坚持只使用当前与历史信息构造特征。

5 模型设计与工程实现

5.1 五个 horizon 分别建模

由于 label_5、label_10、label_20、label_40、label_60 对应不同预测窗口,其类别分布、价格移动幅度和交易价值均不同,项目没有将五个标签混为一个任务,而是为每个 horizon 单独训练一个三分类 XGBoost 模型。

5.2 XGBoost 多分类模型

最终主线模型采用 XGBoost,目标函数为 multi:softprob,输出三类概率。训练阶段使用统一的 922 维特征向量;推理阶段根据模型输出概率和分标签阈值决定最终输出 0、1 或 2。若模型置信度不足,则输出 1,相当于不产生方向交易信号。

表 3: 最终主线训练参数

参数	设置
objective	multi:softprob
max_depth	8
learning rate	0.05
rounds	2000
early stopping	100
regularization	alpha = 10, lambda = 2, gamma = 0.5

5.3 分标签推理阈值

不同 horizon 的价格移动幅度和信号稀疏程度不同，因此项目对不同标签设置不同置信阈值。短 horizon 更容易产生小幅噪声，因此使用更严格阈值；长 horizon 收益空间更大，因此阈值适当放宽。

表 4: 最终推理阈值

标签	最终阈值	逻辑
label_5	0.88	短 horizon 更严格
label_10	0.82	高 precision + 控制覆盖
label_20	0.78	中等覆盖
label_40	0.70	长 horizon 放宽
label_60	0.65	收益空间更大

5.4 工程实现与复现保障

本项目的工程工作不仅包括模型训练，还包括训练-推理特征一致性检查、代码结构整理、提交包修复和平台推理速度优化。工程阶段的核心目标是：把本地训练得到的五个 XGBoost 模型，稳定地转化为平台可导入、可复现、可快速推理，且训练-推理特征完全一致的提交系统。

- 特征 parity:** 对旧版与新版特征生成流程进行一致性检查，使 182 个基础因子和 922 维最终特征的名称、顺序和抽样数值保持一致，避免训练阶段和推理阶段出现特征错位。
- 工程结构:** 项目整理为 `train.py`、`Predictor.py`、`build_submission.py` 和 `smoke test` 等组件，使训练、推理、打包和提交前检查形成相对清晰的流程。
- 缓存与批量化处理:** 面对 922 维高维特征和较大样本规模，训练与推理阶段通过缓存文件、批量化处理和稳定的数据组织方式，降低内存压力并提高代码运行稳定性。
- 提交包修复:** 修复 `flat zip`、`package-relative import`、`batch size` 等问题，保证平台能够正确导入和运行代码，避免本地可运行但平台无法评测的情况。
- Turbo 推理:** 对推理流程进行 `batch` 化和加速优化，并进行 256-window parity 检查，结果为 0 mismatch；推理速度约为 5.7 秒每 batch，降低平台运行时间风险。

这些工程环节对平台结果非常关键。即使本地模型有效，如果提交包导入路径、运行时间或特征口径不一致，平台评测也无法正确反映模型能力。

6 实验迭代过程

6.1 迭代主线

项目主要经历了以下迭代：

- **score-threshold**：早期按官方 score proxy 选择阈值，形成较平衡的本地基线；
- **avg-PnL min1pct**：本地均值更高，但平台当时只完成 3 个任务，因此未纳入最终完整结果对比；
- **高阈值**：极端提高概率阈值，验证 precision 与收益之间的关系；
- **profit-weight**：训练时强调大波动样本，观察 recall 与 precision 的变化；
- **Date63 + turbo**：最终采用 out-of-time 日期切分，并修复平台运行效率，形成最终主线版本。

6.2 结果展示口径

为了避免混合不同口径的实验结果，最终报告只比较五个任务都有结果的三个版本：

表 5：纳入最终比较的三个完整版本

版本	结果口径	覆盖	纳入原因
V1 Index score-threshold	本地验证	5/5	早期完整基线，展示阈值选择后的可用信号
V2 高阈值平台提交	平台	5/5	验证高 precision 与高收益之间并非等价
V3 Date63 holdout turbo	平台	5/5	最终主线版本，包含 out-of-time 切分和运行时修复

明确排除的结果包括：avg-PnL min1pct 的部分平台任务结果、label_20 单模型复现，以及外部 leaderboard 样例。需要特别注意，V1 是本地验证结果，V2 和 V3 是平台结果，因此 absolute PnL 不能直接横向排序，主要用于还原迭代决策过程。

7 实验结果

7.1 三版结果对比

表 6: 三版完整结果对比

版本	口径	五任务均值	PnL 摘要
V1 Index score-threshold	本地验证	P 0.683 / R 0.0526 / F0.5 0.200	Val PnL 162.90
V2 高阈值提交	平台	P 0.911 / R 0.00055 / F0.5 0.0028	Total PnL -0.87
V3 Date63 turbo	平台	P 0.672 / R 0.0514 / F0.5 0.1945	Total PnL 40.60

三个版本的读法如下：V1 是较平衡的本地基线，但仍有平台泛化风险；V2 的 precision 很高，但信号过稀疏；V3 是最终主线版本，3/5 个标签的 model score 为正。




图 2: 三个完整版本的五任务平均分类指标

V2 高阈值版本说明，单纯追求极高 precision 会导致信号覆盖率极低，recall 接近 0，最终 F0.5 和 PnL 都较差。V3 恢复了覆盖率，虽然 precision 低于 V2，但 F0.5 和 PnL 明显改善，是当前最终主线版本。

7.2 最终平台结果

最终采用 Date63 holdout + turbo 版本。平台结果如下：

表 7: Date63 holdout + turbo 最终平台结果

Label	Precision	Recall	F0.5	Total PnL	Single	Score
label_5	0.8014	0.0518	0.2058	-0.42	-0.000054	-0.000425
label_10	0.7625	0.0660	0.2450	2.10	0.000147	-0.000156
label_20	0.6233	0.0694	0.2400	11.72	0.000761	0.000312
label_40	0.5919	0.0412	0.1612	14.61	0.001104	0.000798
label_60	0.5819	0.0289	0.1204	12.59	0.001179	0.000731




图 3: 最终平台版本不同 horizon 的 total PnL




图 4: 最终平台版本不同 horizon 的 precision、recall 与 F0.5

最终结果表明: label_20、label_40、label_60 的 model score 为正, 说明较长 horizon 更容易形成具有正收益期望的方向信号。label_40 的 score 最高, label_60 的 single PnL 较高。label_5 和 label_10 的 precision 较高, 但 single PnL 和 score 仍低于平台基准, 说明短 horizon 即使方向判断相对准确, 单笔价格移动幅度也可能不足以形成有效收益。

8 结果解释与经验总结

8.1 分类概率不等于预期收益

高阈值版本 V2 的 precision 达到 0.911, 但 recall 只有 0.00055, F0.5 仅为 0.0028, total PnL 为负。这说明模型输出的高分类置信度并不必然对应高收益。金融预测中, 交易价值不仅取决于方向是否正确, 还取决于价格移动幅度、信号数量、交易分布和平台评分方式。

8.2 阈值是核心超参数

推理阈值同时影响 signal coverage、precision、recall、F0.5 和 PnL。过低阈值会产生过多噪声信号, 过高阈值会导致信号过于稀疏。最终版本采用分标签阈值, 是因为不同 horizon 的标签分布和收益空间不同, 统一阈值难以兼顾所有任务。

8.3 日期切分更接近真实评估

采用 Date63 out-of-time holdout 后, 验证方式更接近真实未来预测场景, 减少同日市场状态泄露风险。对于高频股票数据, 随机划分可能让模型在训练集中见过与验证集极其相似的市场片段, 导致本地结果虚高。因此, 日期切分虽然可能让验证更困难, 但更可信。

8.4 长 horizon 更适合收益目标

最终平台结果中, label_20、label_40、label_60 的 score 为正, 短 horizon 的 score 为负或接近负。原因可能是短 horizon 内价格移动幅度太小, 虽然方向 precision 较高, 但单笔 PnL 不足; 长 horizon 的方向预测更难, 但一旦预测正确, 价格移动空间更大, single PnL 和 model score 更容易转正。

8.5 工程一致性影响最终成绩

项目过程中, feature parity、提交包结构、导入路径、推理速度和 batch 设计都直接影响平台评估。最终版本进行 parity check 和 turbo 推理修复, 说明量化机器学习项目并不只是本地训练模型, 还需要保证训练、验证、推理和提交环境中的特征口径完全一致。

9 不足与后续优化方向

9.1 从方向概率转向交易期望值

当前模型主要预测方向类别概率, 但平台最终还会考虑 PnL 和 model score。因此, 后续可以引入 signed return 或 expected PnL 预测, 把模型目标从“方向分类正确”进一步转向“交易期望值为正”。一种可行方案是两阶段模型: 第一阶段判断方向, 第二阶段判断该方向信号是否具有足够收益空间。

9.2 概率校准与排序模型

当前推理主要依赖固定阈值筛选 `softprob`。后续可以进行概率校准，或使用排序模型直接学习哪些信号更值得交易，从而替代单纯基于最大类概率的阈值规则。

9.3 分组阈值稳定性

不同股票、不同日期、上午/下午 session 可能存在不同的波动结构和流动性状态。后续可以按日期段、股票和 session 分组分析阈值稳定性，避免统一阈值在某些子样本中失效。

9.4 短 horizon 强化收益过滤

`label_5` 和 `label_10` 的 precision 较高，但 score 为负，说明短 horizon 需要更强的收益过滤。后续可强化 OFI、最优价变化、成交冲击、bid/ask 更新速度等更短周期的微观结构特征，并增加对价格移动幅度的预测。

9.5 长 horizon 强化趋势与成交流量

`label_20`、`label_40`、`label_60` 已经出现正 score。后续可以进一步强化趋势、波动、成交流量和跨窗口一致性特征，以提高长 horizon 中高收益信号的召回率。

9.6 提交 QA 流程标准化

平台提交前应固定 QA 流程，包括：包结构检查、导入路径检查、依赖最小化、原始/加速推理 parity check、batch benchmark 和平台 smoke test。这样可以减少非模型因素导致的失败。

10 总结

本项目完整经历了从数据理解、EDA、数据清洗、标签验证、特征工程、XGBoost 建模、阈值推理、工程提交到平台结果分析的流程。项目的主要工作量体现在三个方面：

- 数据与特征层面：**系统检查 1521 个快照文件，发现缺失文件组合、crossed book、midprice mismatch、amount_delta 极端右偏和标签类别不均衡，并围绕订单簿结构构造 922 维最终特征向量。
- 模型与实验层面：**为五个 horizon 分别训练 XGBoost 三分类模型，通过 `softprob` 和分标签阈值控制交易信号，比较本地基线、高阈值平台提交和 Date63 turbo 最终版本。
- 工程与提交层面：**完成特征 parity、代码结构整理、缓存与批量化处理、提交包修复、batch 推理加速和平台 smoke test，使模型能够稳定进入平台评测。

最终平台版本在 `label_20`、`label_40`、`label_60` 上取得正 model score，五个 horizon 的 total PnL 合计为 40.60。结果也表明，金融预测任务不能只追求分类 precision，更应围绕覆盖率、收益空间和 positive expected value 信号进行建模。后续优化方向是从单纯方向分类转向收益感知建模，并继续提高长 horizon 召回率和短 horizon 收益过滤能力。

A 附录：最终结果快速复盘

表 8: 最终版本核心结论

问题	结论
哪个版本作为最终主线?	V3 Date63 holdout + turbo。
为什么不是高阈值版本?	高阈值版本 precision 高, 但 recall 极低, F0.5 与 PnL 均失败。
哪些 horizon 表现较好?	label_20、label_40、label_60 的 model score 为正。
哪个 horizon 的 score 最高?	label_40。
哪个 horizon 的 single PnL 较高?	label_60。
短 horizon 的问题是什么?	label_5 / label_10 precision 高, 但价格移动幅度不足, score 仍低于平台基准。
后续最重要改进是什么?	从方向概率转向 expected PnL / positive-EV 信号筛选。

B 附录：报告中使用的关键数字

表 9: 关键数字索引

项目	数值
理论文件组合数	1580
实际读取文件数	1521
缺失文件组合数	59
原始总样本行数	3,040,479
原始字段数	35
阶段性特征工程样本数	2,889,900
阶段性特征工程模型特征数	207
最终基础因子数	182
最终 XGBoost 输入维度	922
最终平台五任务 total PnL	40.60
最终平台正 score 标签数	3/5